

Point Hebdo 5

Un aperçu de notre scraper

→ La bdd que vous avez n'est pas finale. Il faut faire tourner le scraper encore qqs fois et croiser les bases ensemble. C'est normal qu'il y ait pas de données pour BMW, elles sont dans une base à part pour l'instant

Scraping de la Wayback machine

- Pour les sites web des usines allemandes, il existe qqs archives dans la wayback machine. Dans le cas de BMW, ils remontent jusqu'en 2017.
- La majorité de temps est passée à modifier le code. La plupart d'essais n'ont pas été productifs car les sites archives sont très hétérogènes. (mais là ça va mieux, et ce n'est pas encore terminé)
- Dans le cas BMW, ça a plutôt bien marché car la structure de leurs pages web est très fluide et elle est restée la même.
- Pour le reste, c'est moins évident : les sites sont moins archivés que BMW ou ont trop changé entre temps et les sites Mercedes n'ont pas d'identifiant numérique ce qui complique les choses un peu

Le scraper

Comment ça marche, en court :

- Requêtes directes à la Wayback Machine, via 2 endpoints : le CDX API (pour trouver les snapshots disponibles) et le replay endpoint (pour récupérer le HTML brut sans la toolbar Wayback).
- Pour chaque usine : découvrir les snapshots 2017-2025 -> pour chaque année, télécharger un snapshot -> extraire le nombre d'employés via des regex spécifiques à la marque.

Quelques détails :

- 4 marques supportées (VW, Audi, Mercedes, BMW), chacune avec ses propres patterns. Ex. BMW dit "Insgesamt zaehlt der Standort rund 17.000 Mitarbeiter", Mercedes dit "21.500 Anzahl Mitarbeiter im Jahr 2023".
- Pour VW/Audi, les URLs ont un id numérique stable (ex. -6811). On l'utilise comme filtre côté serveur Wayback pour retrouver les anciens pages (le nom de la page change, l'id non).
- Pour Mercedes (pas d'id), on essaie aussi les anciens domaines (corporate.mercedes-benz.com, daimler.com) avec le nom de la ville comme filtre.
- Pour chaque chiffre extrait, on capture aussi l'année de référence (parsée depuis "Stand: 12/2022" par ex.) : ca permet de distinguer année du snapshot vs année réelle de la donnée.

Pros de cette approche :

- Les données, si scrapables, sont fiables
- Si on arrive à avoir un code robuste, on peut l'adopter pour les autres pays plus tard (il me semble que j'ai déjà un bon scraper)
- On peut manuellement vérifier les résultats

Cons de cette approche :

- Impossible de tout scraper : comme les sites changent bcp, c'est impossible d'adapter le code à chaque changement ! On peut intégrer qqs stratégies de debug pour les problèmes susceptibles d'être rencontrés mais absolument pas tout !
- La Wayback machine est capricieuse : parfois le server fonctionne et parfois il est très long ou on est bloqués. Il y a des petites solutions mais au détriment du temps de scraping. Par ex. Deux à trois heures pour générer la bdd que vous avez. De plus, chaque run diffère par rapport à l'archive qu'il accède. C-à-d parfois un run sort des années que l'autre run n'a pu sortir et vice versa. Donc le mieux est de run le scraper plusieurs fois et de croiser les bases à la fin

La bdd générée par le scraper

Le scraper sort 3 fichiers CSV :

- **long.csv** : une ligne par (usine, année) avec toutes les tentatives + le statut (found, not_found, no_archive, etc.). Utile pour debugger.
- **wide_by_snapshot_year.csv** : tableau pivote, une colonne par année (l'année = celle du snapshot Wayback).
- **wide_by_reference_year.csv** : même idée, mais l'année = celle à laquelle le chiffre se réfère vraiment. Plus précis (ex. un snapshot 2024 qui dit "Stand 2022" ira dans la colonne 2022).

Variables importantes du long.csv :

- **employees** : le chiffre.
- **reference_year** : l'année à laquelle la donnée se réfère.
- **snippet** : le bout de texte d'où on l'a extrait, pour vérif manuelle => pratique pour la qualité.
- **pattern** : le regex qui a matché (utile si on doit améliorer l'extraction).
- **archive_url** : le lien Wayback de la page utilisée, pour aller revoir la source.

➔ un fichier checkpoint est sauvegardé au fur et à mesure, donc si le run plante ou si tu le coupes, tu reprends où tu en es la prochaine fois.