

Quelques contacts

Des syndicats + contacts par usines parfois + mail type

→ Les contacts sont regroupés dans une bdd qui s'appelle Auto_Plants_Contacts.xlsx

Différence du système syndical entre la France et l'Allemagne

- En Allemagne, les syndicats sont différents de ceux de la France. Je pense qu'ils représentent une industrie entière plutôt qu'une marque
- La majorité des salariés de l'automobile sont représentés par un seul grand syndicat (IG Metall). Donc, les employés de VW, Mercedes, BMW appartiennent généralement au même syndicat --> représentation moins fragmentée
- Le système syndical allemand contient deux volets :
 - le syndicat négocie les conventions collectives par secteur (salaires, temps de travail, etc.)
 - les conseils d'entreprise (work councils ou *Betriebsräte*) représentent les salariés au niveau de l'entreprise.
- Chaque site a son propre work council, et ces councils peuvent être coordonnés au niveau de l'entreprise
- Toutefois, dans la bbd, j'ai combiné des contacts à tous les niveaux s'ils me paraissaient pertinents

Subject: Academic Data Request: Historical Plant-Level Employment and Production Figures (CIRED / SPECULAR Project)

Dear [Contact Name],

I am writing to you on behalf of the International Research Center on Environment and Development (CIRED), a public research institute affiliated with the French National Centre for Scientific Research (CNRS) and École des Ponts ParisTech.

We are currently conducting an independent, multi-institutional research initiative titled SPECULAR (funded under the European/French PEPR SPLEEN framework). Our research focuses on assessing the socio-economic impacts of structural shifts in the European automotive industry, specifically the transitions of fleet electrification and evolving vehicle characteristics, and their long-term implications for industrial employment and greenhouse gas emissions.

To construct an accurate, empirical economic model for our prospective analyses, we are building a historical panel dataset at the individual plant level. We are kindly requesting your assistance in providing or directing us to the following public or historical figures for [Insert Plant Name]:

1. Annual Overall Headcount (Employment Data): Historical total headcount figures for this specific facility for the longest period available.
2. Annual Production Volume: The total number of units manufactured at this specific plant per year over the same timeframe, if available.

This data will be used strictly for public-interest academic research, aggregate econometric modeling, and the formulation of strategic policy recommendations aimed at supporting the resilience of industrial employment across Europe.

If these exact multi-year, plant-specific figures are compiled in a specific sustainability annex, historical database, or if there is a more appropriate department we should contact, please let us know.

Thank you very much for your time, consideration, and support of European industrial research.

Sincerely,

[Names]

[Roles], SPECULAR Project

CIRED (Centre International de Recherche sur l'Environnement et le Développement)

[Email Address]

[Link to Project / CIRED Website: [links]]

Le scraper étendu

Scraper les anciens urls (anciens domaines) quand ils existent

→ Lorsque on mets un url dans la wayback machine, il s'agit de l'url actuel que l'usine utilise en ce moment. On peut néanmoins trouver sur internet les anciens urls pour la même usine avant que la marque ne change de domaine. Cela aide parfois à remonter plus longtemps dans le passé

Comment ca marche ?

- Nous pouvons trouver les anciens urls des pages web des usines → une historique plus longue dans la wayback machine.
- Si on est chanceux, on peut tracer tous les updates des pages web des usines. Dans le cas Ford, c'était tout à fait possible et donc on a une bdd pour toutes les usines avec le chiffre d'emploi de 2006 à 2026 (dans le cas de Ford c'était facile car ils mettent toutes les usines dans une liste sur la même page web, mais pour les autres marques telles que Peugeot et Fiat, il n'y a pas d'info sur l'emploi par usine, que ce soit avant ou après Stellantis)
- Après avoir vérifié les anciennes bdd générées par le scraper, j'ai découvert pas mal d'incohérences. J'ai donc essayé une nouvelle approche afin d'avoir un scraper plus solide (voir slides d'après)

Le scraper hybride

on combine maintenant regex + LLM

→ Le scraper précédent (uniquement basé sur des regex) sortait parfois des faux positifs (ex. il extrayait le total mondial du groupe BMW au lieu du nombre d'employés de l'usine). J'ai ajouté un LLM pour vérifier les cas suspects et pour interroger les pages où aucune regex ne matche

Comment ça marche : regex d'abord, LLM en filet de sécurité

Pour chaque page Wayback récupérée :

1. On essaie les regex spécifiques à la marque (gratuit)
2. Si un regex large matche un chiffre élevé ($\geq 50\,000$), il demande à un LLM (dans mon cas Claude Haiku) : "C'est l'usine de cette ville, ou le total du groupe ?"
→ si le LLM dit "groupe" ou "incertain", le scraper rejette la valeur et cherche un autre match.
3. Si aucun regex ne matche, il demande au LLM d'extraire directement le chiffre + l'année de référence (avec garde-fous : le chiffre doit littéralement apparaître dans la page, être proche d'un mot-clé "Mitarbeiter / employees / Beschäftigte", et une année de référence obligatoire)

En plus :

- Détection élargie des marqueurs "groupe" autour du nombre (BMW Group, Konzern, weltweit, "in over 100 countries", etc.). la valeur est rejetée sans même appeler le LLM si l'un de ces marqueurs est dans une fenêtre de 200 caractères autour du match
- Vérification post-traitement : si le même chiffre + la même `reference_year` apparaissent pendant 3 années consécutives ou plus pour une usine, on les marque "found_stuck" (souvent un signe que la page n'est pas mise à jour, ou qu'une fausse valeur détectée par le LLM)

Pros et Cons de cette approche

Pros :


- Précision améliorée : on intercepte les faux positifs typiques. Ex. avant, BMW Eisenach affichait 124 729 en 2018-2021 (= total BMW Group mondial). Maintenant ces lignes sont rejetées ou marquées comme suspectes.
- Meilleur recall : le LLM trouve des chiffres dans des pages dont le format ne correspond à aucune regex (sites moins standardisés, sites où les chiffres sont reportés en photos, surtout les pages Mercedes legacy).
- Cache séparé pour le LLM → on ne refait pas la même requête deux fois, ce qui accélère (énormement) les reruns

Cons :

- Coût API : 0.5\$ par run complet (pour une base de ~250 url à vérifier). Pas énorme, mais non nul
- Les anciens sites de Mercedes (sans id numérique, format peu standardisé) restent les plus difficiles. la combinaison regex + LLM n'aide pas trop

Percentage of scraped employment data per Plant

Plant Name



- A côté se trouve les pourcentages des données remplies par usine allemande en utilisant l'approche Regex + LLM

- La période sur laquelle s'étend ce run est 2006-2026

- J'ai vérifié les rapports financiers/activité de ces marques pour consolider : Il n'y a pas l'info sur l'emploi par usine à l'exception de VW où on trouve cette info pour six usines allemandes et uniquement à partir de 2014

le scraper ressemble a ca quand il est en train de tourner. (Vous avez également ces infos dans la bdd générée)

```
=====
PLANT: Audi Plant Ingolstadt [audi] DE_AUDI_INGOLSTADT (4 URLs)
CDX [PLANT_SPECIFIC] http://www.audi.com/corporate/de/company/production-sites/audi-production-worldw → 1468 snapshots (cached)
CDX [PLANT_SPECIFIC] http://www.audi.com/corporate/en/company/production-sites/audi-production-worldw → 1468 snapshots (cached)
CDX [PLANT_SPECIFIC] https://www.audi-mediacycenter.com/en/audi-in-ingolstadt-5543 → 200 snapshots (cached)
CDX [PLANT_SPECIFIC] https://www.audi-mediacycenter.com/de/audi-in-ingolstadt-5543 → 200 snapshots (cached)
2006: no_archive https://www.audi-mediacycenter.com/en/audi-in-ingolstadt-5543
2007: no_archive https://www.audi-mediacycenter.com/en/audi-in-ingolstadt-5543
2008: no_archive https://www.audi-mediacycenter.com/en/audi-in-ingolstadt-5543
2009: FOUND_LLM 31501 ref=2007 slot=primary
2010: FOUND_LLM 32707 ref=2009 slot=primary
2011: FOUND 32819 ref=2010 [audi_corporate_employees_as_at] slot=primary
2012: FOUND 33729 ref=2011 [audi_corporate_employees_as_at] slot=primary
2013: FOUND 35386 ref=2012 [audi_corporate_employees_as_at] slot=primary
2014: no_archive https://www.audi-mediacycenter.com/en/audi-in-ingolstadt-5543
2015: FOUND 40027 ref=2014 [audi_corporate_employees_as_at] slot=primary
2016: FOUND 43192 ref=2015 [audi_corporate_employees_as_at] slot=primary
2017: FOUND 43952 ref=2016 [audi_corporate_employees_as_at] slot=primary
2018: FOUND 43952 ref=2016 [audi_corporate_employees_as_at] slot=primary
2019: not_found https://www.audi-mediacycenter.com/en/audi-in-ingolstadt-5543
2020: FOUND_LLM 44458 ref=2019 slot=primary
2021: not_found http://www.audi.com/corporate/de/company/production-sites/au
2022: FOUND 42436 ref=2021 [audi_arbeiten_plain] slot=primary
2023: FOUND_LLM 40118 ref=2022 slot=primary
2024: FOUND_LLM 40000 ref=2023 slot=primary
2025: FOUND_LLM 40000 ref=2024 slot=primary
2026: FOUND_LLM 40000 ref=2024 slot=primary
```