

Point Hebdo 7

Communiquer l'approche IA dans les article scientifiques + des
infos supplementaires sur les scrapers

Comment montrer l'utilisation de l'IA dans les papiers scien

- J'ai trouvé une revue systématique qui liste l'utilisation du web scraping dans quelques centaines d'études.
- Plusieurs études récentes ont utilisé les LLM pour scraper des données, ou les ont utilisés en parallèle avec des API, des regex, etc.
- Bref, communiquer cette approche de manière structurée dans un article scientifique n'est pas très compliqué.
- Je joins au dossier dont nous allons discuter aujourd'hui cette revue, ainsi que quelques papiers avec des passages surlignés dont nous pouvons nous inspirer pour rédiger nos résultats.

Peut-on utiliser ERM pour consolider ?

- Pas vraiment. Les informations qui nous manquent sur l'emploi sont souvent anciennes (avant 2016). Or, la base ERM ne contient pas forcément des URL pour les anciens événements de restructuration. Dans la colonne de source, ils mettent simplement : « trouvé dans un journal allemand ». Ils mettent également le snippet mais l'info sur l'emploi total de l'usine ne s'y trouve pas.
- De plus, pour les anciens événements de restructuration, j'ai remarqué que le lieu de l'événement est manquant : on n'a pas l'usine en question.

- **Peut-on utiliser Wikipédia pour consolider ?**

- C'est une meilleure alternative, c'est sûr, mais il y a un trade-off de qualité à faire car les chiffres sont souvent différents de ceux communiqués sur les sites des usines.
- Le mieux je pense serait de faire un autre scraper pour wiki si j'estime qu'il y a pas mal de données à scraper.
- Je le ferai ajd ou ce week-end le temps de finir avec l'intégration des autres usines européennes pour les constructeurs allemands.

Coût d'une API payante (Haiku)

Par appel au LLM (extraction ou validation)

- Input : ~3 500–4 800 tokens (texte de la page tronqué à 12 000 caractères + prompt)
- Prix Haiku 4.5 (version la moins chère) : 1€/M tokens en input, 5€/M en output
- → Chaque appel coûte environ 0,4 centime). Extraction et validation ont quasi le même coût

Coût page → URL → usine

- Par snapshot Wayback : 0 € si regex matche, ~0,004 € si on tombe sur le LLM, ~0,008 € dans le pire cas (extraction + validation)
- Par URL (21 ans, jusqu'à 5 snapshots/an) : ~5–20 appels LLM après cache → environ 0,02–0,10 €
- Par usine (3 URLs en moyenne) : ~20–50 appels LLM → environ 0,10–0,30 \$.

→ Le regex économise beaucoup : les pages où ça matche ne coûtent rien. Le LLM ne tourne que sur les pages où le regex échoue ou est suspecte

Coût d'un run complet (43 usines × 21 ans)

Trois scénarios selon le taux de succès du regex et du cache

- Meilleur scénario (regex matche beaucoup, cache plein) : ~150 appels LLM → ≈ € 0,70
- scénario typique : ~400 appels LLM → ≈ € 1,80
- Pire scénario (regex marche peu) : ~1500 appels → ≈ € 6,40

→ En pratique, prévoir 3–5 euros de crédit Anthropic suffit largement, pour un ou deux reruns (à comparer entre eux, vu que la Wayback renvoie des snapshots différents à chaque run)

API gratuite gemini

- L'API gratuite arrive à extraire presque la moitié des résultats trouvés par l'API payante de haiku. Et précision parfois un peu en-dessous de Haiku
- Pourtant, je préfère attendre de rerun tous les scrapers gemini avec les nouvelles usines européennes ajoutées avant de faire un verdict final

Le RAG est-il bénéfique pour notre tâche ?

- Le RAG n'apporterait probablement qu'un gain limité, pcq le principal problème n'est pas la qualité de l'extraction mais la récupération des données.
- Si j'ai bien compris, le RAG repère le bon document ou le bon segment où se trouve l'information, mais on a déjà cette info. Le problème est l'inexistence des urls/archives pour les anciennes pages.
- Les bottlenecks rencontrés jusqu'à présent concernent surtout la disponibilité des données :
 - Données non archivées : si aucun document n'existe, le RAG ne peut rien récupérer
 - Pages générées en JS : l'information n'apparaît pas dans le HTML, donc le RAG ne trouve rien
 - Pages correctement récupérées : lorsque le bon texte est disponible, les modèles extraient déjà correctement les chiffres d'emploi